

Reporte del Proyecto 2 – Analítica de datos sobre resultados Saber 11 (Cesar, Colombia)

Juan Camilo Medina – 202122966

Nicolás Salazar – 202124147

María Inés Velásquez – 202224323

Contents

Resumen ejecutivo	2
¿Cuál es el puntaje global esperado de un estudiante del Cesar, tomando como base sus características socioeconómicas, y cuáles de estas características son las que más influyen?	3
Detalle de pregunta.....	3
Análisis de datos	3
Hallazgos asociados.....	3
¿Es posible predecir si un estudiante proviene de un colegio bilingüe basándose en su desempeño académico y características socioeconómicas?	4
Detalle de la pregunta	4
Análisis de datos	4
Hallazgos asociados	4
¿Qué puntaje puede esperar un estudiante en cada área de las pruebas Saber 11 según su contexto escolar y familiar?	5
Detalle de pregunta	5
Análisis de datos	5
Hallazgos asociados.....	6
Elementos principales del tablero	6
Ambiente de despliegue y mantenimiento	7

Resumen ejecutivo

Este proyecto desarrolla un producto de analítica predictiva sobre los resultados de las pruebas Saber 11 en el departamento del Cesar, orientado a apoyar la toma de decisiones del Ministerio de Educación Nacional y secretarías de educación municipales. A partir de 63,127 registros de estudiantes (periodos 2014-2 -> 2022-4), se construyeron tres modelos predictivos basados en redes neuronales, desplegados en un tablero interactivo en Dash sobre AWS con contenedores Docker.

Pregunta 1: Predicción del puntaje global. Una red neuronal de regresión (arch_D_deep: 256+BN+Drop->128+BN+Drop->64+Drop->32) con 457 features alcanza MAE=28.65 y $R^2=0.356$, superando a XGBoost y quedando a menos del 0.7% de MAE de CatBoost. El análisis SHAP revela que los códigos DANE del establecimiento, la jornada nocturna/sabatina, el carácter oficial del colegio y el acceso a computador e internet son los factores de mayor peso predictivo. El contexto observable explica el 36% de la varianza del puntaje global.

Pregunta 2: Identificación de colegios bilingües. Una red neuronal de clasificación profunda (128->64->32->16 con BatchNorm y Dropout) entrenada con class weights para manejar el fuerte desbalance de clases (1.96% de positivos) alcanza AUC-ROC=0.967, Recall=78.2% y Precision=54.3%. El modelo permite reducir el número de colegios a evaluar de 50,000 a cerca de 1,500 candidatos manteniendo la detección del 78% de los casos positivos. El puntaje de inglés, el estrato y la naturaleza del colegio son los predictores más relevantes.

Pregunta 3: Predicción multi-output por área. Una red neuronal de regresión con 5 neuronas de salida (256->128->64 con BatchNorm) predice simultáneamente los puntajes en las cinco áreas a partir de variables contextuales previas al examen, alcanzando R^2 promedio de 0.291 y MAE promedio de 6.885 puntos. El hallazgo más relevante es que inglés es la materia más determinada por el contexto ($R^2=0.363$), mientras que sociales es la menos predecible ($R^2=0.249$), lo que indica una dependencia de factores individuales no observables. Este resultado conecta directamente con la pregunta 2: el bilingüismo institucional y el estrato socioeconómico son los principales determinantes del desempeño en inglés.

Los tres modelos fueron rastreados con MLflow, serializados en archivos locales y desplegados pre-entrenados en el tablero. El producto final es accesible vía web en una instancia EC2 t2.large, construido con Docker sobre el puerto 8050, y permite a cualquier usuario interactuar con los tres modelos ingresando el perfil de un estudiante y obteniendo predicciones en tiempo real.


¿Cuál es el puntaje global esperado de un estudiante del Cesar, tomando como base sus características socioeconómicas, y cuáles de estas características son las que más influyen?

Detalle de pregunta La pregunta busca predecir el puntaje global de un estudiante del Cesar en las pruebas Saber 11, el error para este valor predicho, y aquellas variables que más influyen en la predicción. Se implementa una red neuronal de regresión con una neurona de salida, complementada con modelos de árbol de decisión boosting como benchmark y análisis SHAP para interpretabilidad.

Análisis de datos: Tras limpieza y filtrado se trabajó con 63,127 registros. Se codificaron variables binarias, se recodificaron categóricas y se aplicó one-hot encoding, obteniendo una matriz de 457 features con puntaje global como variable objetivo. Los puntajes por área fueron excluidos para evitar data leakage. Se definieron cinco conjuntos de features para evaluar el impacto de la información institucional, el completo (full_457, 457 features), una variante ordinal (full_ordinal, 423), sin códigos de establecimiento (no_estab, 287), sin todos los códigos DANE (no_dane, 107) y una variante ordinal reducida (ordinal_small, 73).

Se evaluaron 6 arquitecturas de red neuronal densa con normalización, Adam y MSE como función de pérdida, con EarlyStopping, registrando 15 runs en MLflow. En la Fase 1 la ganadora fue arch_D_deep (256+BN+Drop->128+BN+Drop->64+Drop->32), con MAE=28.74 y $R^2=0.355$ sobre full_457. En la Fase 2, eliminar los códigos DANE produjo una caída de 1.9 puntos de MAE ($R^2=0.269$ vs 0.356), lo cual confirma que la identidad del colegio es el predictor de mayor peso. En la Fase 3, large_batch (lr=1e-3, batch=512) resultó óptimo con MAE=28.648 y $R^2=0.356$.

El modelo final alcanza MAE=28.65, RMSE=35.97 y $R^2=0.356$. Como benchmark se entrenaron XGBoost ($R^2=0.353$) y CatBoost ($R^2=0.367$). La red neuronal supera a XGBoost y queda a solo 0.19 puntos de MAE de CatBoost, diferencia que justifica su uso en el dashboard por mayor compatibilidad con SHAP.



Hallazgos asociados: Los códigos DANE del establecimiento, jornada nocturna/sabatina, carácter oficial, calendario A y acceso a computador e internet son los factores de mayor peso predictivo según SHAP. El contexto observable explica el 36% de la varianza del puntaje global; el 64% restante corresponde a factores individuales no medidos.

¿Es posible predecir si un estudiante proviene de un colegio bilingüe basándose en su desempeño académico y características socioeconómicas?

Detalle de la pregunta: La investigación busca predecir si un estudiante proviene de un colegio bilingüe a partir de sus resultados en Saber 11 y variables socioeconómicas, especialmente el puntaje en inglés, el estrato y la naturaleza del colegio.

Esto permitiría al Ministerio de Educación identificar colegios con potencial de certificación bilingüe y priorizar recursos de validación, reduciendo costos y optimizando el proceso de evaluación.

Análisis de datos: Se trabajó con 66.869 registros válidos de Saber 11 del Cesar (2022–2024). El conjunto presentaba un fuerte desbalance: solo el 1,96% correspondía a estudiantes de colegios bilingües (1:50).

Se utilizaron 13 variables relacionadas con desempeño académico y características socioeconómicas. Para manejar el desbalance se aplicaron class weights y una división estratificada de los datos (80% entrenamiento, 20% prueba).

Se desarrolló una red neuronal profunda en TensorFlow/Keras con arquitectura [128, 64, 32, 16], incorporando BatchNormalization y Dropout. La optimización se realizó con MLflow mediante 10 experimentos enfocados en arquitectura, BatchNormalization y learning rate, seleccionando el modelo con mejor AUC-ROC en validación.

El análisis exploratorio mostró que los estudiantes de colegios bilingües obtienen en promedio 55,9 puntos en inglés frente a 48,1 de los no bilingües, confirmando que el puntaje de inglés es el predictor más relevante del modelo.

Hallazgos asociados: El modelo final alcanzó un AUC-ROC de 0,967, Recall de 78,2% y Precision de 54,3%, mostrando una alta capacidad de identificación de colegios bilingües.

En términos operativos, permite reducir el universo de evaluación de 50.000 colegios a cerca de 1.500 candidatos, manteniendo la detección del 78% de los casos positivos.

Además del puntaje de inglés, las variables más relevantes fueron la naturaleza del colegio, el estrato socioeconómico y el acceso a recursos tecnológicos en el hogar.


¿Qué puntaje puede esperar un estudiante en cada área de las pruebas Saber 11 según su contexto escolar y familiar?

Detalle de pregunta: La pregunta busca predecir de manera simultánea los puntajes en matemáticas, lectura crítica, ciencias naturales, sociales y ciudadanas e inglés, a partir de variables contextuales a priori como jornada escolar, naturaleza del colegio (oficial/no oficial), área de ubicación (urbano/rural), calendario académico y nivel educativo de los padres. Para esto, se implementó una red neuronal de regresión con 5 neuronas de salida.

Análisis de datos: Para la primera fase, se exploraron diferentes arquitecturas con el set de features completo, con optimizador Adam= 1×10^{-3} . La mejor fue la cuarta arquitectura (256->128->64; MAE=6.87, $R^2=0.291$), que supera a otras con mayor profundidad o menor capacidad.

En la Fase 2 se compararon tres conjuntos de features en la cuarta arquitectura. El feature set completo (455 features, $R^2=0.292$) supera al conjunto sin códigos DANE (105 features, $R^2=0.223$) y al solo contextual (53 features, $R^2=0.202$). Como se nota, la diferencia entre estos dos últimos es pequeña, lo cual indica que las variables familiares ya capturan la mayoría del poder de predicción de la parte contextual. Para la Fase 3 se ajustó la configuración de train de la cuarta arquitectura. Adam $lr=1e-3$ con batch=32 fue la mejor (MAE=6.86, $R^2=0.294$).

La configuración óptima convergió en 21 épocas con early stopping. Esta red alcanza un MAE promedio de 6.885 puntos y R^2 promedio de 0.291. El



desempeño varía por materia; inglés es la más predecible ($R^2=0.363$, MAE=6.574), seguida de ciencias naturales ($R^2=0.292$), matemáticas ($R^2=0.289$) y lectura crítica ($R^2=0.263$). Sociales y ciudadanas es la menos predecible ($R^2=0.249$, MAE=7.459).

Hallazgos asociados: inglés es la materia más predecible dado el panorama contextual ($R^2=0.363$). Esto es esperado, dado que en Colombia el acceso al idioma está altamente determinado por estrato, naturaleza del colegio y bilingüismo; lo cual se conecta con la segunda pregunta de negocio. Sociales es la menos predecible ($R^2=0.249$), esto indica que su desempeño puede depender de otros factores (posiblemente no observables). Eliminar los códigos de sede reduce el R^2 de 0.29 a 0.22, indicando que cada colegio tiene características no medidas que afectan el desempeño. El 70.9% de varianza restante corresponde a factores individuales no observables, que determinan el desempeño educativo.

Elementos principales del tablero

El dashboard integra tres modelos predictivos desarrollados en Dash y Plotly, desplegados en infraestructura AWS EC2. Su interfaz basada en pestañas permite la generación de predicciones de forma intuitiva, sin requerir conocimientos técnicos.

Pregunta 1 – Predicción de Puntaje Global:

Este módulo estima el puntaje global esperado de un estudiante en una escala de 0 a 500, a partir del nivel educativo de los padres y características del contexto escolar. El modelo genera 457 variables mediante one-hot encoding. Los resultados se presentan mediante un gauge con codificación por niveles de desempeño, intervalos de confianza y un análisis de interpretabilidad con los cinco factores más influyentes mediante SHAP values. El desempeño del modelo se evalúa con MAE, RMSE y R^2 .

Pregunta 2 – Clasificación de Colegios Bilingües:

Este módulo clasifica las instituciones educativas como BILINGÜE o NO BILINGÜE a partir de 12 variables, que incluyen puntajes Saber 11 (seis áreas), características institucionales (naturaleza y jornada) y condiciones socioeconómicas del estudiante (género, estrato, acceso a internet y computador). El resultado se presenta mediante una etiqueta de clasificación, un gauge de probabilidad (0–100%), una explicación en lenguaje natural y la identificación de factores determinantes. El modelo corresponde a una red neuronal con arquitectura [128, 64, 32, 16], ajustada con class weights (50x) debido al fuerte desbalance de clases (1.96% bilingües). Su desempeño alcanza un AUC-ROC de 0.967 y un Recall de 78.2%.

Pregunta 3 – Predicción Multiárea:


Este módulo predice simultáneamente los puntajes en cinco áreas del conocimiento utilizando variables del contexto escolar y familiar. Los resultados se visualizan mediante gráficos de barras horizontales con intervalos de confianza y un radar chart comparativo frente al promedio departamental. El desempeño del modelo se evalúa mediante MAE y R^2 por cada área.

Funcionalidades generales:

La plataforma incorpora validación de datos en tiempo real, carga de modelos preentrenados en formato .keras y mensajes de error descriptivos para el usuario. Sus principales casos de uso incluyen la evaluación de perfiles estudiantiles, la simulación de escenarios educativos, la identificación de instituciones con potencial de certificación bilingüe, el análisis de brechas educativas y la autoevaluación institucional.

Ambiente de despliegue y mantenimiento

Para el despliegue, utilizamos una instancia de EC2 en AWS de tipo t2.large. Dentro de ella, importamos el contenido de nuestro repositorio con la información para desplegar el tablero, es decir, la carpeta *data_dashboard*. Luego, habilitamos el puerto 8050 con protocolo de acceso TCP desde cualquier dirección IPV-4 para que los usuarios puedan acceder al dashboard de cualquier lugar. Siguiendo, instalamos en la MV las dependencias y paquetes para usar Docker, y como contábamos con el Dockerfile en nuestra carpeta importada, solo bastó crear la imagen, y desplegar el contenedor. Hecho esto, se puede acceder al dashboard a través de la URL <http://34.203.229.76:8050/> (al momento de este informe), tal como se ve en la imagen:



Finalmente, para el mantenimiento, podemos revisar la 'salud' del contenedor por medio de comandos como: *docker ps* y *docker logs -f icfes-dashboard*. Ante cambios y actualizaciones, basta con actualizar los archivos importados, y bajar: *docker compose down* y subir *docker compose up -d --build* el contenedor y su imagen.